MINI-PROJET 01

Détection du breast cancer

1 Contexte et problématique

À partir de caractéristiques extraites d'images de cellules, construire et comparer plusieurs classifieurs capables de distinguer les tumeurs bénignes des tumeurs malignes. L'enjeu n'est pas de produire un outil clinique, mais d'étudier les compromis entre performance globale et détection des cas malins.

Question centrale : Quel modèle classe le mieux les observations, et lequel limite le risque de ne pas identifier une tumeur maligne ?

2 Jeu de données public

Source	Breast Cancer Wisconsin (Diagnostic) — UCI Machine Learning Repository
Description	569 observations · 30 variables numériques · 2 classes
Variable cible	Diagnostic : tumeur bénigne (B) ou maligne (M)

Accès et téléchargement : fiche officielle UCI | https://archive.ics.uci.edu/dataset/17/breast-cancer-wisconsin-diagnostic

3 Algorithmes à comparer (Liste non exhaustive)

Méthode de Machine Learning	Hyperparamètre(s) à étudier
Régression logistique	C, régularisation
K plus proches voisins (KNN)	nombre de voisins k
Arbre de décision	profondeur maximale
Random Forest	nombre d'arbres, profondeur
SVM	noyau, C et gamma

4 Évaluation des performances

Accuracy, Precision, Recall, F1-score, ROC-AUC et matrice de confusion. Mettre particulièrement en avant le rappel de la classe maligne.

5 Protocole expérimental obligatoire

1. Importer la base ; décrire les variables, les dimensions et les éventuelles valeurs manquantes ; produire une analyse exploratoire pertinente.
2. Séparation stratifiée 80 % apprentissage / 20 % test, avec graine aléatoire fixée.
3. Définir un prétraitement adapté.
4. Implémenter les cinq modèles proposés ou plus ; justifier les choix et rechercher au moins un hyperparamètre pour quatre modèles.
5. Évaluer les modèles uniquement à la fin sur le jeu de test ; synthétiser les performances dans un tableau comparatif.
6. Interpréter les résultats.

6 Visualisations minimales

- Répartition des deux classes et distribution de plusieurs caractéristiques.
- Matrices de confusion de deux modèles au minimum.
- Courbes ROC comparées ; tableau récapitulatif des scores.

7 Livrables attendus

Notebook Jupyter / Python	Code exécutable, documenté et reproductible, avec graphiques et résultats.
Rapport (3 à 5 pages)	Contexte, préparation, méthodologie, résultats, discussion et conclusion.
Présentation (8 à 10 min)	Synthèse des choix, comparaison des modèles et recommandations.