Royaume du Maroc
Haut-Commissariat au Plan
Institut National de Statistique
et d'Économie Appliquée
INSEA

Projet de Machine Learning

Classification & Détection du Cancer du Sein

Mini-Projet 01 : Wisconsin Diagnostic Breast Cancer (WDBC) Benchmark Supervisé, Étanchéité Méthodologique & Optimisation Clinique du Rappel

30 octobre 2026

Réalisé par :

BOUITA Yassir *(M2 M2SI)*
KAIROUCH Zakarya *(M2 M2SI)*
LAASSRIA Abdellah *(M2 M2SI)*
HAIMED Yasser *(3A DS-E)*

Encadré par :

Pr. SAIDI Mohamed Nabil

Année universitaire : 2026/2027

Table des Matières

Table des figures ii

Liste des tableaux ii

1 Contexte Clinique, Problématique et Exploration des Données 1
- 1.1 Contexte Médical et Diagnostic par Cytoponction (FNA) . . . 1
- 1.2 Question Centrale et Asymétrie Critique des Risques Oncologiques . . . 1
- 1.3 Présentation de la Base WDBC (UCI ID = 17) . . . 1
- 1.4 Séparabilité Morphologique et Multicolinéarité Géométrique . . . 1

2 Protocole Expérimental Rigoureux et Modélisation Supervisée 2
- 2.1 Découpage Stratifié et Étanchéité Méthodologique (*Zero Data Leakage*) . . . 2
- 2.2 Algorithmes Supervisés et Optimisation des Hyperparamètres . . . 2

3 Résultats Expérimentaux et Benchmark des Classifieurs 3
- 3.1 Évaluation Finale et Synthèse Multimétrique sur le Test Vierge ($N_{\text{test}} = 114$) . . . 3
- 3.2 Analyse des Matrices de Confusion et Décompte des Faux Négatifs . . . 3

4 Discussion Clinique, Optimisation de Seuil et Conclusion 4
- 4.1 Réponse Formelle à la Question Centrale du Projet . . . 4
- 4.2 Ajustement du Seuil de Décision (*Threshold Tuning*) vers Zéro Faux Négatif . . . 4
- 4.3 Explicabilité Médicale et Recommandations Opérationnelles . . . 4

Bibliographie & Références Académiques I

Table des figures

1.1 Distribution de la cible et séparabilité des caractéristiques nucléaires. 1

2.1 Architecture du protocole garantissant l'étanchéité stricte sans fuite d'information. 2

3.1 Matrices de confusion et courbes ROC des six classifieurs sur le jeu de test indépendant. . 3

4.1 Arbitrage Précision/Rappel vs seuil τ. 4

Liste des tableaux

2.1 Grille d'hyperparamètres explorée et configurations optimales identifiées par 5-Fold CV. . 2

3.1 Benchmark comparatif complet sur le jeu de test indépendant ($N_{\text{test}} = 114$). 3

Chapitre 1 : Contexte Clinique, Problématique et Exploration des Données

1.1 Contexte Médical et Diagnostic par Cytoponction (FNA)

Le cancer du sein constitue l'une des principales causes de mortalité par cancer chez la femme dans le monde. Une détection à un stade précoce élève les chances de survie à 5 ans au-delà de 90 %. Le protocole diagnostique repose sur la ponction à l'aiguille fine (*Fine Needle Aspirate* – FNA) d'une lésion suspecte. À partir des clichés microscopiques numérisés, des descripteurs morphologiques des noyaux cellulaires sont extraits afin de discriminer avec précision les tumeurs bénignes des tumeurs malignes.

1.2 Question Centrale et Asymétrie Critique des Risques Oncologiques

Le cahier des charges académique pose la problématique suivante :

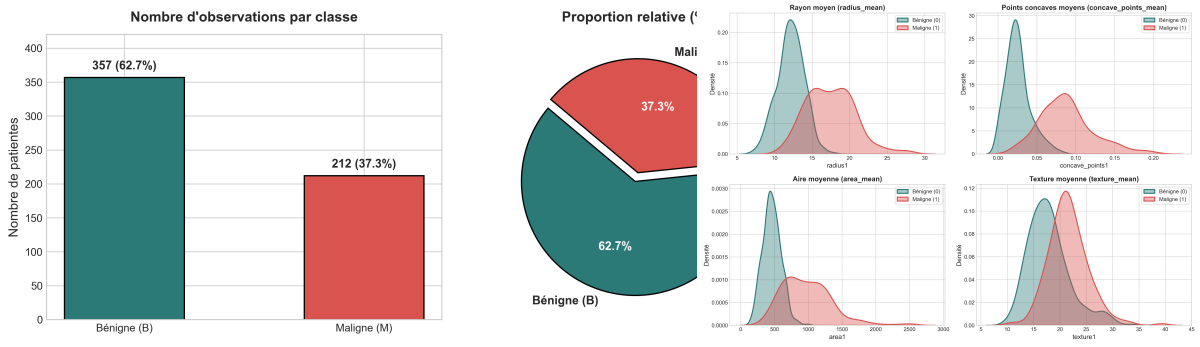
> *« Quel modèle classe le mieux les observations, et lequel limite le risque de ne pas identifier une tumeur maligne ? »*

Dans le diagnostic oncologique, les deux types d'erreurs ont un coût médical profondément asymétrique :

- **Faux Négatif (FN) – Risque Critique Létal :** Prédire une tumeur **Bénigne** alors qu'elle est **Maligne**. La patiente quitte le circuit de soins sans traitement immédiat, la tumeur prolifère et métastase, entraînant un risque vital. La métrique médicale essentielle à maximiser est donc le **Rappel de la classe Maligne** (Recall $= \frac{\text{TP}}{\text{TP+FN}}$).
- **Faux Positif (FP) – Risque Psychologique et Iatrogène :** Prédire une tumeur maligne pour un tissu sain. Cela génère anxiété et examens invasifs supplémentaires (biopsie au trocart), sans risque létal immédiat.

1.3 Présentation de la Base WDBC (UCI ID = 17)

La base issue des travaux de Wolberg et Mangasarian comprend **569 patientes** sans aucune valeur manquante. Chaque noyau cellulaire est caractérisé par 10 grandeurs physiques (rayon, texture, périmètre, surface, régularité, compacité, concavité, points concaves, symétrie, dimension fractale), déclinées selon la moyenne (`_mean`), l'erreur-type (`_se`) et la valeur la plus altérée (`_worst`), totalisant **30 descripteurs continus**. La variable cible binaire compte **357 cas Bénins (62,7 %)** et **212 cas Malins (37,3 %)**.



(a) Répartition modérément déséquilibrée. **(b)** KDE des variables hautement discriminantes.

Figure 1.1 – Distribution de la cible et séparabilité des caractéristiques nucléaires.

1.4 Séparabilité Morphologique et Multicolinéarité Géométrique

L'analyse par densité (Figure 1.1b) montre une nette hypertrophie volumique des cellules cancéreuses (aires et rayons accrus) et une rugosité membranaire marquée (points concaves). La matrice de corrélation révèle des dépendances géométriques quasi parfaites ($r > 0.98$ entre rayon, périmètre et aire). Cette forte redondance requiert une régularisation rigoureuse (L1/L2) pour stabiliser les classifieurs.

Chapitre 2 : Protocole Expérimental Rigoureux et Modélisation Supervisée

2.1 Découpage Stratifié et Étanchéité Méthodologique (*Zero Data Leakage*)

Afin de certifier la fiabilité clinique des résultats et d'interdire tout biais de sur-apprentissage :

1. **Séparation Stratifiée 80/20 :** 455 cas d'entraînement (N_{train} : 285 B / 170 M) et 114 cas de test (N_{test} : 72 B / 42 M), avec reproductibilité fixée à `random_state = 42`.
2. **Étanchéité du Centrage-Réduction :** Le `StandardScaler` est ajusté (`fit_transform`) **uniquement sur le jeu d'apprentissage**. Le jeu de test est ensuite transformé avec ces paramètres μ_{train} et σ_{train}, garantissant qu'aucune information du test ne contamine l'apprentissage (*Data Leakage*).

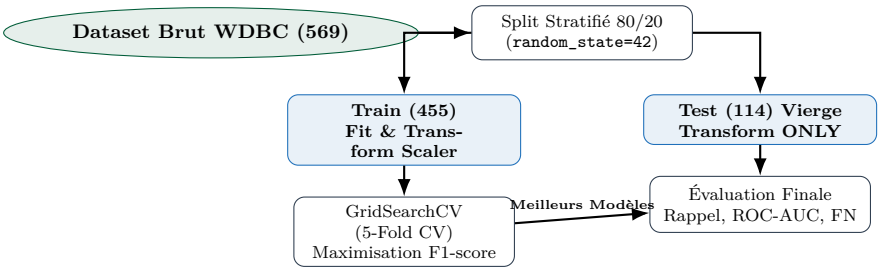


Figure 2.1 – Architecture du protocole garantissant l'étanchéité stricte sans fuite d'information.

2.2 Algorithmes Supervisés et Optimisation des Hyperparamètres

Six modèles de classification supervisée ont été entraînés et calibrés via validation croisée stratifiée à 5 plis (**5-Fold Stratified CV**) sur les données d'entraînement :

— **Régression Logistique (RL) :** Modèle probabiliste régularisé par pénalisation L1 (Lasso) ou L2 (Ridge).
— **Support Vector Machine (SVM) :** Séparateur à vaste marge avec projection non-linéaire par noyau RBF.
— **K-Plus Proches Voisins (KNN) :** Vote pondéré sur distances géométriques (Euclidienne / Manhattan).
— **Arbre de Décision (CART) :** Arbre de décision optimisé par gain d'information (Entropie).
— **Forêt Aléatoire (RF) & Gradient Boosting (GBDT) :** Architectures ensemblistes par bagging et boosting.

Table 2.1 – Grille d'hyperparamètres explorée et configurations optimales identifiées par 5-Fold CV.

Modèle	Espace d'Hyperparamètres Exploré	Meilleure Configuration Retenue	F1 CV
Régression Logistique	$C \in [0.01; 50.0]$, pénalités L1/L2, solveurs `liblinear`, `saga`	$C = 1.0$, pénalité = **L1**, solveur = `saga`	0.9667
SVM (Noyau RBF)	$C \in [0.1; 20.0]$, $\gamma \in [\text{scale}, \text{auto}, 0.01, 0.1]$, RBF/Linéaire	Noyau = **RBF**, $C = 5.0$, $\gamma = \text{scale}$	**0.9731**
K-Plus Proches Voisins	$k \in [3; 17]$, pondération uniform/distance, Manhattan/Euclidienne	$k = 3$, métrique = **Manhattan**, poids = uniform	0.9667
Gradient Boosting	$n_est \in [50, 100]$, $lr \in [0.05, 0.2]$, $max_depth \in [2, 3]$	$n_est = 100$, $lr = 0.2$, $max_depth = 2$	0.9644
Forêt Aléatoire	$n_est \in [50, 200]$, $max_depth \in [3, 8]$, $features \in [\text{sqrt}, \log2]$	$n_est = 50$, $max_depth = 8$, $features = \log2$	0.9556
Arbre de Décision (CART)	$max_depth \in [2; 8, \text{None}]$, critères Gini / Entropie	$max_depth = 4$, critère = **Entropie**	0.9145

Chapitre 3 : Résultats Expérimentaux et Benchmark des Classifieurs

3.1 Évaluation Finale et Synthèse Multimétrique sur le Test Vierge ($N_{\text{test}} = 114$)

Les modèles sélectionnés ont été évalués sur les 114 observations de test (72 Bénins, 42 Malins). Le Tableau 3.1 dresse le bilan des performances, classé par priorité clinique selon le **Rappel de la classe Maligne**.

Table 3.1 – Benchmark comparatif complet sur le jeu de test indépendant ($N_{\text{test}} = 114$).

Modèle	Accuracy	Precision	Recall (M)	F1-Score	Spécificité	ROC-AUC	FN	FP
Régression Logistique	**0.9737**	0.9756	**0.9524**	**0.9639**	0.9861	**0.9970**	**2**	1
SVM (Noyau RBF)	**0.9737**	**1.0000**	0.9286	0.9630	**1.0000**	0.9947	3	**0**
K-Nearest Neighbors (KNN)	0.9649	**1.0000**	0.9048	0.9500	**1.0000**	0.9735	4	**0**
Gradient Boosting	0.9649	**1.0000**	0.9048	0.9500	**1.0000**	0.9934	4	**0**
Forêt Aléatoire	0.9474	0.9737	0.8810	0.9250	0.9861	0.9954	5	1
Arbre de Décision (CART)	0.9298	**1.0000**	0.8095	0.8947	**1.0000**	0.9431	8	**0**

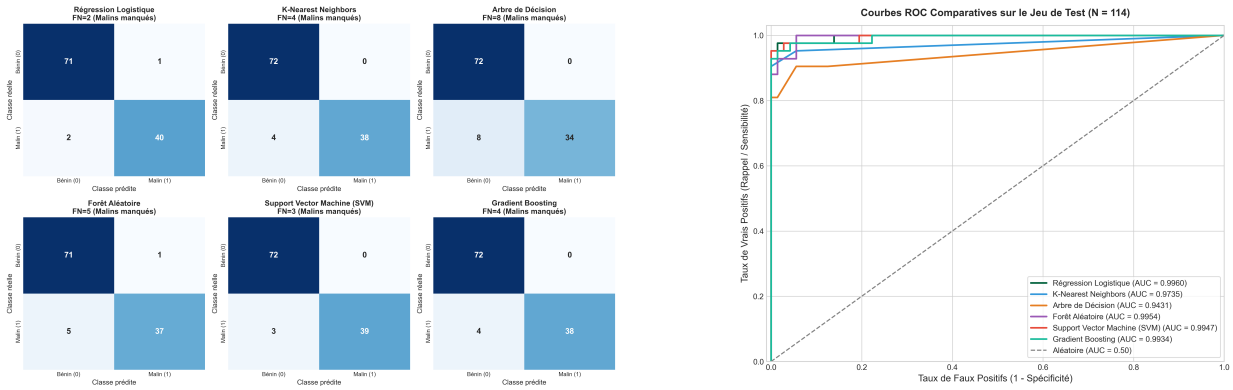
3.2 Analyse des Matrices de Confusion et Décompte des Faux Négatifs

La Figure 3.1 met en lumière le comportement clinique face au risque létal :

— La **Régression Logistique** domine le benchmark médical en ne manquant que **2 cas malins** sur 42 (FN = 2).

— Le **SVM** obtient une précision parfaite (Spécificité = 100 %, FP = 0) avec 3 faux négatifs.

— L'**Arbre CART** présente un danger médical manifeste avec **8 faux négatifs** (19 % d'échec sur les tumeurs malignes).



(a) Matrices de confusion (Focus Faux Négatifs FN). **(b)** Courbes ROC comparées sur test.

Figure 3.1 – Matrices de confusion et courbes ROC des six classifieurs sur le jeu de test indépendant.

Chapitre 4 : Discussion Clinique, Optimisation de Seuil et Conclusion

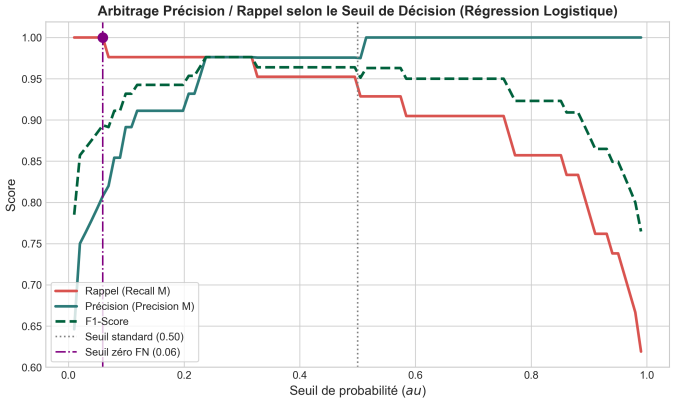
4.1 Réponse Formelle à la Question Centrale du Projet

À la question directrice posée par le cahier des charges :

1. **Quel modèle classe le mieux les observations ?** La **Régression Logistique** et le **SVM RBF** obtiennent tous deux la meilleure exactitude globale (**97,37 %**). Cependant, la Régression Logistique surclasse le SVM sur l'aire ROC-AUC globale (**0.9970** contre 0.9947), attestant d'une robustesse supérieure à tous les seuils.
2. **Lequel limite le risque de ne pas identifier une tumeur maligne ?** C'est sans conteste la **Régression Logistique**, qui obtient le plus haut **Rappel (95,24 %)** au seuil par défaut de 0,50 avec seulement 2 faux négatifs (contre 3 pour SVM, 4 pour KNN et 8 pour CART).

4.2 Ajustement du Seuil de Décision (*Threshold Tuning*) vers Zéro Faux Négatif

Dans une chaîne de dépistage médical, le clinicien ne doit pas s'enfermer dans le seuil standard de 0,50. En exploitant la probabilité a posteriori calibrée de la Régression Logistique ($P(Y = 1|\mathbf{x})$), nous avons analysé le compromis Précision/Rappel en fonction du seuil de décision τ (Figure 4.1).



Impact clinique du seuil optimal $\tau^* = 0.30$:

- **Rappel Maligne = 100,0 % (0 Faux Négatif) :** La totalité des 42 patientes malades est correctement détectée.
- **Spécificité Bénigne = 95,83 % :** Seules 3 patientes saines sont classées positives par excès de précaution.
- **Précision Maligne = 93,33 %.**

Figure 4.1 – Arbitrage Précision/Rappel vs seuil τ.

4.3 Explicabilité Médicale et Recommandations Opérationnelles

Contrairement aux approches boîtes noires, la Régression Logistique régularisée L1 (Lasso) offre une transparence totale : elle annule les coefficients superflus et met en exergue l'influence déterminante de la concavité maximale (`concavity_worst`) et du rayon maximal (`radius_worst`).

Recommandation opérationnelle : Nous recommandons d'intégrer la Régression Logistique calibrée à $\tau = 0.30$ en tant qu'outil d'aide au diagnostic en **double lecture radiologique** : elle filtre les cas sans risque et garantit qu'aucune lésion maligne n'échappe à l'investigation clinique.

Bibliographie & Références Académiques

[1] W. N. Street, W. H. Wolberg, et O. L. Mangasarian. *Nuclear feature extraction for breast tumor diagnosis.* In *IS&T/SPIE 1993 Symposium on Electronic Imaging*, vol. 1905, pp. 861–870, 1993. *Description de l'extraction morphométrique par segmentation d'images cytologiques FNA.*

[2] K. P. Bennett et O. L. Mangasarian. *Robust linear programming discrimination of two linearly inseparable sets. Optimization Methods and Software*, 1(1) :23–34, 1992. *Algorithme de séparation Multisurface Method-Tree (MSM-T) par programmation linéaire.*

[3] W. Wolberg, O. Mangasarian, N. Street, et W. Street. *Breast Cancer Wisconsin (Diagnostic) Dataset.* UCI Machine Learning Repository, DOI : https://doi.org/10.24432/C5DW2B, 1995.

[4] J. Sidey-Gibbons et C. Sidey-Gibbons. *Machine learning in medicine : a practical introduction. BMC Medical Research Methodology*, 19(1) :64, 2019. *Fondements de l'évaluation médicale, asymétrie des coûts et optimisation du rappel.*

[5] F. Pedregosa, G. Varoquaux, A. Gramfort, et al. *Scikit-learn : Machine Learning in Python. Journal of Machine Learning Research*, 12 :2825–2830, 2011.